

2026년도 머신러닝 기반 데이터 분석 과제

AI개발 수행내역서

과제명	AI 기반 스마트팜 작물 추천 모델 개발 및 시각화
담당자	정재봉

2026년 6 월 24 일

AI개발 수행내용

1. 사업과제 : AI 기반 스마트팜 작물 추천 모델 개발 및 시각화

2. 개요 및 현황

2.1. 추진배경 및 목적

- 스마트팜 대시보드는 **센서 환경값(온·습도·토양)**만 보여줄 뿐, 무엇을 심고 어떻게 관리할지 판단은 사람의 몫으로 남아 있음
- 단순 임계값 알림(예: 온도 30℃ 초과 시 팬 가동)은 누구나 구현 가능하여 **차별성이 없고**, 데이터 기반의 능동적 의사결정 지원이 부재함
- 장기간 축적되는 환경·토양 데이터를 학습하여, **초보 재배자도 데이터에 근거해 작물을 선택**하도록 돕는 자동 추천 모델의 수요가 증대
- 본 과제는 정형 데이터 기반 작물 추천(시범 모델)을 구축하고, 향후 **잎 사진 병 진단(DL)·자연어 처방(LLM)**으로 확대하기 위한 1단계 모델을 개발하고자 함

2.2. 과제 범위

과제구분		내용
모델	AI 기반 작물 추천 모델 개발	원시 데이터 수집 및 데이터셋 구축
		데이터 전처리, 상관관계 분석 (EDA 도구 활용)
		분류모델 선정 및 학습 (LogReg·RandomForest·XGBoost)
		Accuracy·Precision·Recall·F1-Score 평가지표를 활용한 모델 성능평가
시각화	모델 평가 및 테스트	예측실행 웹앱 프로토타입 구축 (Streamlit)
		모델 평가 시각화 테스트

2.3. 과제 추진 방법

1) 구축 대상 선정 기준

- 데이터 접근성 및 활용성
 - 편의성 : 공개 데이터셋(Kaggle) 및 공공데이터 활용 가능 여부
 - 모델학습 유용성 : 종속변수(작물)에 영향을 주는 독립변수 정보 포함 및 적정 학습 데이터양
- 추천모델 개발 효율성
 - 변수가 상대적으로 단순한 구조(수치형 7개)로 학습·평가 과정 간소화 여부
 - 개발된 학습·평가 골격을 다른 단계(DL·LLM)에 재사용 가능 여부
- 재배 의사결정 기여도
 - 초보 재배자의 시행착오·비용 절감 및 데이터 기반 농업 확산 기여 여부

2) AI 추천 분석모델 적용 대상

추천 기능	수집 데이터	독립변수	종속변수
작물 추천 (스마트팜)	- Kaggle Crop Recommendation 데이터셋 2,200건 - 토양 양분·기후 변수 포함	총 7개 입력 변수 - 토양양분 : N(질소), P(인), K(칼륨) - 산도 : pH - 기후 : 온도, 습도, 강수량	- 작물 분류 (label : 작물 22종)

3) AI 분석모델 구축 프로세스

DATA IMPORTING	AUTO PREDICTION	USER INSIGHT
Kaggle 작물 데이터 수집·임포트 1. 결측치 확인 2. 변수별 상관관계 분석 3. 훈련/테스트 데이터 분할	데이터 전처리 → 모델링 → 예측 모델 성능 비교 및 최적 분류모델(RandomForest) 도출	환경값 기반 적합 작물 추천 1. 사용자 웹 UI 제공(Streamlit) 2. 모델 평가·시각화 제공

연구개발 주요 결과물

1. 데이터 수집

- Kaggle Crop Recommendation Dataset — 작물 22종 × 100건 = 2,200건 (입력 7 + 정답 1)

2. 데이터 분석

2.1. 변수 구성

구분	변수(영문)	설명	범위
입력(X)	N	토양 질소	0 ~ 140
입력(X)	P	토양 인	5 ~ 145
입력(X)	K	토양 칼륨	5 ~ 205
입력(X)	temperature	평균 온도(°C)	8.8 ~ 43.7
입력(X)	humidity	상대 습도(%)	14.3 ~ 100.0
입력(X)	ph	토양 산도	3.5 ~ 9.9
입력(X)	rainfall	강수량(mm)	20.2 ~ 298.6
정답(y)	label	적합 작물	22종

2.2. 판단결과 (종속변수)

분류(label)	작물 22종 : rice, maize, chickpea, banana, mango, grapes, apple, orange, coffee, cotton 등
-----------	--

- 클래스 분포 : 22종 × 100개 완전 균형 → 정확도(Accuracy) 지표 신뢰 가능

2.3. 데이터 샘플

N	P	K	temperature	humidity	ph	rainfall	label
90	42	43	20.9	82.0	6.5	202.9	rice
85	58	41	21.8	80.3	7.0	226.7	rice
60	55	44	23.0	82.3	7.8	264.0	rice
74	35	40	26.5	80.2	7.0	242.9	rice
78	42	42	20.1	81.6	7.6	262.7	rice
69	37	42	23.1	83.4	7.1	251.1	rice

3. 탐색적 데이터 분석

3.1. 데이터 요약

- 2,200 rows × 8 columns 으로 구성 (입력 7개는 수치형, 정답 1개는 범주형)
- 결측치 없음(Missing 0) · 중복 없음 · 22종 × 100개 완전 균형

3.2. 데이터 전처리

- 입력 7개가 모두 수치형이라 원-핫 인코딩이 불필요하며, 정답(작물명)만 LabelEncoder로 숫자(0~21) 변환
- 학습/테스트 = 8:2 분할 (stratify로 22종 비율 유지) → 1,760 / 440
- 스케일링은 train에만 fit 후 test는 transform만 적용 → 데이터 누수 방지

```

from sklearn.preprocessing import LabelEncoder, StandardScaler
from sklearn.model_selection import train_test_split


le = LabelEncoder()
    y = le.fit_transform(df['label'])      # rice->0 ... coffee->21
    X = df.drop(columns=['label'])         # 입력 7개 (전부 수치형)

X_tr, X_te, y_tr, y_te = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y)

scaler = StandardScaler()
X_tr = scaler.fit_transform(X_tr)         # train만 fit
X_te = scaler.transform(X_te)            # test는 transform만

```

3.3. 변수 상관관계 (독립변수 선택)



- P(인)-K(칼륨) 상관 0.74 외에는 대부분 독립적 → 다중공선성 부담 낮음 → 7개 변수 모두 사용

그림 1 변수 간 상관관계 Heatmap

- 작물별 강수량 분포가 뚜렷이 다름(머스크멜론 약 25mm vs 벼 약 236mm) → 강수량이 작물 구분의 핵심 변수




그림 2 입력 변수 7종 분포 (히스토그램)




그림 3 작물별 강수량 분포 (박스플롯)

4. 모델 정의 및 학습

4.1. 모델 정의 및 비교

- LogisticRegression / RandomForest / XGBoost 세 모델을 동일 데이터로 공정 비교 후 베스트 선정

```
models = {
    'LogisticRegression': LogisticRegression(max_iter=1000),
    'RandomForest': RandomForestClassifier(n_estimators=200, random_state=42, n_jobs=-1),
    'XGBoost': XGBClassifier(n_estimators=200, random_state=42, n_jobs=-1),
}

for name, m in models.items():
    m.fit(X_tr, y_tr)
    print(name, round(accuracy_score(y_te, m.predict(X_te)), 4))
# -> RandomForest 0.995 (best)
```

모델	정확도	비고
LogisticRegression	97.3%	기준선(직선 분리만 가능)
RandomForest	99.5%	★ 베스트 — 데모 채택
XGBoost	99.3%	강력하나 근소 차 2위




그림 4 모델별 정확도 비교

4.2. 모델 학습 및 평가 (베스트 : RandomForest)

- **혼동행렬** : 테스트 440개 중 **438개 정답(오답 2개)** — 환경이 닮은 작물도 안정적으로 분리
- **피쳐 중요도** : **강수량 45% > 습도 29% > pH 10% > 온도 9.5% > N·P·K** → EDA 결과와 일치




그림 5 RandomForest 혼동행렬




그림 6 RandomForest 피쳐 중요도

5. 프로토타이핑 (화면)

5.1. 모델 예측

- 슬라이더 7개로 환경값 입력 → 적합 작물 + 신뢰도(확률) Top 3, '왜 이 작물?' 비교표 제공

 **스마트팜 작물 추천**

토양·환경 값으로 적합 작물 추천 + 모델 평가 (RandomForest 99.5%)

예측하기

작물별 환경 가이드

모델 평가 비교

환경값 입력

질소(N)
50.00

인(P)
50.00

칼륨(K)
50.00

온도(°C)
25.00

습도(%)
70.00

산도(pH)
6.50

강수량(mm)
100.00

작물 추천 받기

 **추천 작물 : 파파야 (papaya)**

추천 신뢰도 Top 3

그림 7 탭1 — 작물 추천 화면

5.2. 작물별 환경 가이드

- 작물 선택 → 적합 환경값(평균·최소·최대)을 표로 안내

스마트팜 작물 추천

토양·환경 값으로 적합 작물 추천 + 모델 평가 (RandomForest 99.5%)

 예측하기  작물별 환경 가이드  모델 평가·비교

작물별 적합 환경 가이드

작물을 고르면 그 작물이 잘 자라는 환경값(평균·범위)을 보여줍니다.

작물 선택

강낭콩

	평균	최소	최대
질소(N)	20.8000	0.0000	40.0000
인(P)	67.5000	55.0000	80.0000
칼륨(K)	20.0000	15.0000	25.0000
온도(℃)	20.1000	15.3000	24.9000
습도(%)	21.6000	18.1000	25.0000
산도(pH)	5.7000	5.5000	6.0000
강수량(mm)	105.9000	60.3000	149.7000

예: 강낭콩는 강수량 평균 106mm, 습도 22% 환경을 좋아합니다.

그림 8 탭2 — 작물별 환경 가이드

5.3. 모델 평가 시각화

- 세 모델 정확도 비교표 + 평가 시각화(막대그래프)를 한 화면에서 제공

스마트팜 작물 추천

토양·환경 값으로 적합 작물 추천 + 모델 평가 (RandomForest 99.5%)

 예측하기

 작물별 환경 가이드

 모델 평가·비교

세 모델 정확도 비교

모델	정확도	비고
RandomForest 🏆	99.5%	베스트(데모 채택)
XGBoost	99.3%	강력하나 근소 패
LogisticRegression	97.3%	기준선




그림 9 탭3 — 모델 평가·비교

6. 결론 및 제안

- 작물 22종을 **정확도 99.5%(RandomForest)**로 추천하는 분류 모델 개발 및 모델 파일 저장(학습↔서빙 분리)
- Streamlit 웹 데모(예측·가이드·평가 3개 탭) 완성 및 평가 시각화 확보
- ML 5단계 골격(수집→EDA→전처리→학습→평가) 체득, '**최신 모델이 항상 1등은 아니다**' 실증○ 한계 및 향후 계획
- 실서비스 제공을 위해서는 **국내 실측 데이터**가 필요 (현재는 공개 데이터 기반)
- Phase 2 (DL) : **잎 사진 → CNN 병해충 진단** (정형 ML로 불가능한 이미지 처리 확장)
- Phase 3 (LLM) : 진단·환경 예측 + 재배지식(RAG) → **자연어 처방 및 알림** 제공