

# 2026년도 공공기관 용역과제 AI개발 수행내역서

|     |                                 |
|-----|---------------------------------|
| 과제명 | AI 기반 스마트팜 작물 추천 모델<br>개발 및 시각화 |
| 담당자 | 정재봉                             |

2026년      6월   24 일

# 목차

|                         |    |
|-------------------------|----|
| I. AI개발 수행내용            | 2  |
| 1. 사업과제                 | 2  |
| 2. 개요 및 현황              | 2  |
| 2.1 추진배경 및 목적           | 2  |
| 2.2 과제 범위               | 2  |
| 2.3 과제 추진 방법            | 3  |
| II. 연구개발 주요 결과물         | 4  |
| 1. 데이터 수집               | 4  |
| 2. 데이터 분석               | 4  |
| 2.1 변수 구성               | 4  |
| 2.2 판단 결과(종속변수)         | 5  |
| 2.3 데이터 샘플              | 5  |
| 2.4 데이터 요약              | 6  |
| 2.5 데이터 전처리             | 6  |
| 2.6 변수 상관관계 Heatmap     | 7  |
| 2.7 자동 EDA 프로파일링(YData) | 10 |
| 3. 데이터 학습 및 모델정의        | 11 |
| 3.1 모델 정의 및 비교          | 11 |
| 3.2 모델 학습 및 평가          | 12 |
| 3.3 하이퍼파라미터 튜닝·과적합 점검   | 13 |
| 4. 프로토타이핑(화면)           | 14 |
| 4.1 모델 예측               | 14 |
| 4.2 작물별 환경 가이드          | 15 |
| 4.3 모델 평가 시각화           | 16 |
| 5. 결론 및 제안              | 17 |

## AI개발 수행내용

### 1. 사업과제 : AI 기반 스마트팜 작물 추천 모델 개발 및 시각화

#### 2. 개요 및 현황

##### 2.1 추진배경 및 목적

- 스마트팜 대시보드는 **센서 환경값(온·습도·토양)**만 보여줄 뿐, 무엇을 심고 어떻게 관리할지 판단은 사람의 몫으로 남아 있음
- 단순 임계값 알림(예: 온도 30℃ 초과 시 팬 가동)은 누구나 구현 가능하며 **차별성이 없고**, 데이터 기반의 능동적 의사결정 지원이 부재함
- 장기간 축적되는 환경·토양 데이터를 학습하여, **초보 재배자도 데이터에 근거해 작물을 선택하도록** 돕는 자동 추천 모델의 수요가 증대
- 본 과제는 정형 데이터 기반 작물 추천(시범 모델)을 구축하고, 향후 **잎 사진 병 진단(DL)·자연어 처방(LLM)으로 확대**하기 위한 1단계 모델을 개발하고자 함

##### 2.2 과제 범위

| 과제구분 |                        | 내용                                                      |
|------|------------------------|---------------------------------------------------------|
| AI   | AI기반 작물 추천 모델 개발       | 원시 데이터 수집 및 데이터셋 구축                                     |
|      |                        | 데이터 전처리, 표준화, 상관관계 분석<br>(EDA도구 활용)                     |
|      |                        | 분류 모델 선정 및 학습<br>(LogReg·RandomForest·XGBoost)          |
|      |                        | Accuracy·Precision·Recall·F1-Score<br>평가지표를 활용한 모델 성능평가 |
| 시각화  | 실시간 환경계측정보 연계 및<br>시각화 | 예측실행 웹앱 프로토타입 구축<br>(Streamlit)                         |
|      |                        | 모델 평가 시각화                                               |

## 2.3 과제 추진 방법

### 1) 구축 대상 선정 기준

#### ○ 데이터 접근성 및 활용성

- 데이터 수집 및 활용성
- 편의성 : 공개 데이터셋(Kaggle) 및 공공데이터 활용 가능 여부
- 모델학습 유용성 : 종속변수(작물)에 영향을 주는 독립변수 정보 포함 및 적정 학습 데이터양

#### ○ 추천모델 개발 효율성

- 변수가 상대적으로 단순한 구조(수치형 7개)로 학습·평가 과정 간소화 여부
- 개발된 학습·평가 골격을 다른 단계(DL·LLM)에 재사용 가능 여부


#### ○ 재배 의사결정

- 초보 재배자의 시행착오·비용 절감 및 데이터 기반 농업 확산 기여 여부

### 2) AI 예측 분석모델 적용 대상

| 추천 기능            | 수집 데이터                                                                                                               | 독립 변수                                                                         | 종속 변수                  |
|------------------|----------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------|------------------------|
| 작물 추천/<br>(스마트팜) | <ul style="list-style-type: none"> <li>- Kaggle Crop Recommendation 데이터셋 2,200건</li> <li>- 토양 양분-기후 변수 포함</li> </ul> | 총 7개 입력 변수<br>- 토양 양분 : N(질소), P(인), K(칼륨)<br>- 산도 : pH<br>- 기후 : 온도, 습도, 강수량 | - 작물 분류(label): 작물 22종 |

### 3) AI 분석모델 구축 프로세스



## 연구개발 주요 결과물

### 1. 데이터 수집

- Kaggle Crop Recommendation Dataset - 작물 22종 x 100건 = 2,200 건 (입력 7 + 정답 1)

| Crop_recommendation |    |    |             |                   |                   |                   |       |  |
|---------------------|----|----|-------------|-------------------|-------------------|-------------------|-------|--|
| N                   | P  | K  | temperature | humidity          | ph                | rainfall          | label |  |
| 90                  | 42 | 43 | 20.87974371 | 82.00274423       | 6.502985292000000 | 202.9355362       | rice  |  |
| 85                  | 58 | 41 | 21.77046169 | 80.31964408       | 7.038096361       | 226.6555374       | rice  |  |
| 60                  | 55 | 44 | 23.00445915 | 82.3207629        | 7.840207144       | 263.9642476       | rice  |  |
| 74                  | 35 | 40 | 26.49109635 | 80.15836264       | 6.980400905       | 242.8640342       | rice  |  |
| 78                  | 42 | 42 | 20.13017482 | 81.60487287       | 7.628472891       | 262.7173405       | rice  |  |
| 69                  | 37 | 42 | 23.05804872 | 83.37011772       | 7.073453503       | 251.0549998       | rice  |  |
| 69                  | 55 | 38 | 22.70883798 | 82.63941394       | 5.70080568        | 271.3248604       | rice  |  |
| 94                  | 53 | 40 | 20.27774362 | 82.89408619       | 5.718627178000000 | 241.9741949       | rice  |  |
| 89                  | 54 | 38 | 24.51588066 | 83.53521630000000 | 6.685346424       | 230.4462359       | rice  |  |
| 68                  | 58 | 38 | 23.22397386 | 83.03322691       | 6.336253525       | 221.2091958       | rice  |  |
| 91                  | 53 | 40 | 26.52723513 | 81.41753846       | 5.386167788       | 264.6148697       | rice  |  |
| 90                  | 46 | 42 | 23.97898217 | 81.45061596       | 7.50283396        | 250.0832336       | rice  |  |
| 78                  | 58 | 44 | 26.80079604 | 80.88684822       | 5.108681786       | 284.4364567       | rice  |  |
| 93                  | 56 | 36 | 24.01497622 | 82.05687182       | 6.98435366        | 185.2773389       | rice  |  |
| 94                  | 50 | 37 | 25.66585205 | 80.66385045       | 6.94801983        | 209.5869708       | rice  |  |
| 60                  | 48 | 39 | 24.28209415 | 80.30025587       | 7.042299069000000 | 231.0863347       | rice  |  |
| 85                  | 38 | 41 | 21.58711777 | 82.7883708        | 6.249050656000000 | 276.6552459000000 | rice  |  |
| 91                  | 35 | 39 | 23.79391957 | 80.41817957       | 6.970859754       | 206.2611855       | rice  |  |
| 77                  | 38 | 36 | 21.8652524  | 80.1923008        | 5.953933276       | 224.5550169000000 | rice  |  |
| 88                  | 35 | 40 | 23.57943626 | 83.58760316       | 5.85393208        | 291.2986618000000 | rice  |  |
| 89                  | 45 | 36 | 21.32504158 | 80.47476396       | 6.442475375       | 185.4974732       | rice  |  |
| 76                  | 40 | 43 | 25.15745531 | 83.11713476       | 5.070175667       | 231.3843163       | rice  |  |
| 67                  | 59 | 41 | 21.94766735 | 80.97384195       | 6.012632591       | 213.3560921       | rice  |  |
| 83                  | 41 | 43 | 21.0525355  | 82.67839517       | 6.254028451       | 233.1075816       | rice  |  |

### 2. 데이터 분석

#### 2.1 변수 구성

| 구분     | 변수(영문)      | 설명        | 범위           |
|--------|-------------|-----------|--------------|
| 입력 (X) | N           | 토양 질소     | 0 ~140       |
| 입력 (X) | P           | 토양 인      | 5 ~145       |
| 입력 (X) | K           | 토양 칼륨     | 5 ~ 205      |
| 입력 (X) | temperature | 평균 온도(°C) | 8.8 ~ 43.7   |
| 입력 (X) | humidity    | 상대 습도(%)  | 14.3 ~ 100.0 |
| 입력 (X) | ph          | 토양 산도     | 3.5 ~ 9.9    |
| 입력 (X) | rainfall    | 강수량(mm)   | 20.2 ~ 298.6 |
| 정답 (y) | label       | 적합 작물     | 22종          |

## 2.2 판단 결과 (종속 변수)

### ○ 분류(label)

- 작물 22종 :rice, maize, jute, cotton, coconut, mango, grapes, apple, orange 등

#### label

Categorical

High correlation Uniform

|              |           |                |      |
|--------------|-----------|----------------|------|
| Distinct     | 22        | rice           | 100  |
| Distinct (%) | 1.0%      | maize          | 100  |
| Missing      | 0         | jute           | 100  |
| Missing (%)  | 0.0%      | cotton         | 100  |
| Memory size  | 137.9 KiB | coconut        | 100  |
|              |           | Other value... | 1700 |

More details

○ 클래스 분포 : 22종 x 100 개 완전 균형 → Accuracy지표 신뢰 가능

## 2.3 데이터 샘플

스마트팜 작물 추천 — Phase 1 EDA (YData Profiling)
Overview
Variables
Interactions
Correlations
Missing values
Sample

A simple visualization of nullity by column.

### Sample

First rows
Last rows


|   | N  | P  | K  | temperature | humidity  | ph       | rainfall   | label |
|---|----|----|----|-------------|-----------|----------|------------|-------|
| 0 | 90 | 42 | 43 | 20.879744   | 82.002744 | 6.502985 | 202.935536 | rice  |
| 1 | 85 | 58 | 41 | 21.770462   | 80.319644 | 7.038096 | 226.655537 | rice  |
| 2 | 60 | 55 | 44 | 23.004459   | 82.320763 | 7.840207 | 263.964248 | rice  |
| 3 | 74 | 35 | 40 | 26.491096   | 80.158363 | 6.980401 | 242.864034 | rice  |
| 4 | 78 | 42 | 42 | 20.130175   | 81.604873 | 7.628473 | 262.717340 | rice  |
| 5 | 69 | 37 | 42 | 23.058049   | 83.370118 | 7.073454 | 251.055000 | rice  |
| 6 | 69 | 55 | 38 | 22.708838   | 82.639414 | 5.700806 | 271.324860 | rice  |
| 7 | 94 | 53 | 40 | 20.277744   | 82.894086 | 5.718627 | 241.974195 | rice  |
| 8 | 89 | 54 | 38 | 24.515881   | 83.535216 | 6.685346 | 230.446236 | rice  |
| 9 | 68 | 58 | 38 | 23.223974   | 83.033227 | 6.336254 | 221.209196 | rice  |

Report generated by YData.

## 2.4 데이터 요약

- 결측치 없음 · 중복 없음 · 22종 x 100개 완전 균형
- 2,200 rows x 8 columns 으로 구성 (입력 7개는 수치형, 정답 1개는 범주형)

## Missing values



## 2.5 데이터 전처리

- 입력 7개가 모두 수치형이라 원-핫 인코딩 불필요, 정답(작물명)만 LabelEncoder로 숫자(0~21) 변환
- 학습/테스트 = 8:2 분할(stratify로 22종 비율 유지) → 1,760/440
- 스케일링은 train 에만 fit후 test는 transform만 적용 → 데이터 누수 방지


```
from sklearn.preprocessing import LabelEncoder, StandardScaler
from sklearn.model_selection import train_test_split

le = LabelEncoder()
y = le.fit_transform(df['label'])      # rice->0 ... coffee->21
X = df.drop(columns=['label'])        # 입력 7개(전부 수치형)

X_tr, X_te, y_tr, y_te = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y)

scaler = StandardScaler()
X_tr = scaler.fit_transform(X_tr)      # train만 fit
X_te = scaler.transform(X_te)         # test는 transform만
```


## 2.6 변수 상관관계 Heatmap(독립변수 선택)




○ P(인) - K(칼륨) 상관 0.74 외에는 대부분 독립적 → 다중공선성 부담 낮음 → 7개 변수 모두 사용

○ 작물별 강수량 분포가 뚜렷이 다름(머스크멜론 약 25mm vs 벼 약 236mm) → **강수량이 작물 구분의 핵심 변수**





○입력 변수 7종 분포 (히스토그램 )



○ 작물별 강수량 분포 (박스플롯)

## 2.7 자동 EDA 프로파일링 (YData Profiling)

- 수동 EDA에 더해 ydata-profiling으로 자동 EDA 리포트를 생성하여,  
기초 통계량과 데이터 품질 경고를 객관적으로 보강함

| 변수      | 평균     | 표준편차  | 최소    | 중앙값   | 최대     |
|---------|--------|-------|-------|-------|--------|
| 질소(N)   | 50.55  | 36.92 | 0.00  | 37.0  | 140.0  |
| 인(P)    | 53.36  | 32.99 | 5.00  | 51.0  | 145.0  |
| 칼륨(K)   | 48.15  | 50.65 | 5.00  | 32.0  | 205.0  |
| 온도(°C)  | 25.62  | 5.06  | 8.83  | 25.6  | 43.68  |
| 습도(%)   | 71.48  | 22.26 | 14.26 | 80.47 | 99.98  |
| 산도(pH)  | 6.47   | 0.77  | 3.50  | 6.43  | 9.94   |
| 강수량(mm) | 103.46 | 54.96 | 20.21 | 94.87 | 298.56 |

- 자동 탐지 경고 11건 :label ↔ (K·P·강수량) 강한연관/ label 균등분포 / 온·습도·pH·강수량 연속형 고유 값 / N 0값 27건(1.2% 결측 아님)

### Alerts

|                                                              |                  |
|--------------------------------------------------------------|------------------|
| K is highly overall correlated with label                    | High correlation |
| P is highly overall correlated with label                    | High correlation |
| humidity is highly overall correlated with label             | High correlation |
| label is highly overall correlated with K and 3 other fields | High correlation |
| rainfall is highly overall correlated with label             | High correlation |
| label is uniformly distributed                               | Uniform          |
| temperature has unique values                                | Unique           |
| humidity has unique values                                   | Unique           |
| ph has unique values                                         | Unique           |
| rainfall has unique values                                   | Unique           |
| N has 27 (1.2%) zeros                                        | Zeros            |

### 3. 데이터 학습 및 모델정의


#### 3.1 모델 정의 및 비교

○ LogisticRegression / RandomForest / XGBoost 세 모델을 통일 데이터로 공정 비교 후 베스트 선정

```
models = {
    'LogisticRegression': LogisticRegression(max_iter=1000),
    'RandomForest': RandomForestClassifier(n_estimators=200, random_state=42, n_jobs=-1),
    'XGBoost': XGBClassifier(n_estimators=200, random_state=42, n_jobs=-1),
}
for name, m in models.items():
    m.fit(X_tr, y_tr)
    print(name, round(accuracy_score(y_te, m.predict(X_te)), 4))
# -> RandomForest 0.995 (best)
```



| 모델                 | 정확도   | 비고             |
|--------------------|-------|----------------|
| LogisticRegression | 97.3% | 기준선(직선 분리만 가능) |
| RandomForest       | 99.5% | □ 베스트 - 데모 채택  |
| XGBoost            | 99.3% | 강력하나 근소 차 2위   |

⑤ 모델별 정확도 비교



### 3.2 모델 학습 및 평가 (베스트: RandomForest)

- 혼동행렬 : 테스트 440개 중 438개 정답(오답 2개) - 환경이 닮은 작물도 안정적으로 분리
- 피쳐 중요도 : 강수량 45% > 습도 29% > pH 10% > 온도 9.5% > N·P·K → EDA 결과 와 일치



### 3.3 하이퍼파라미터 튜닝 및 과적합 점검

- 베이스라인 RandomForest는 Test 정확도가 99.5%로 높으나 Train 정확도가 100%로 학습 데이터를 완벽히 암기하여, 미세한 과적합 경향이 관찰되었다.

이를 완화하기 위해 GridSearchCV(5-fold 교차검증, 후보 36개 조합)로 하이퍼파라미터를 탐색하였다.

- 탐색 대상 : n\_estimators()리 수트, max\_depth(최대 깊이), min\_samples\_split, min\_samples\_leaf

- 최적 조합 : max\_depth =10, min\_samples\_split = 5, n\_estimators = 100, min\_samples\_leaf = 1

| 구분                             | Train Acc | Test Acc | Gap(과적합 정도) |
|--------------------------------|-----------|----------|-------------|
| 튜닝 전<br>(기본값, 트리 200)          | 1.0000    | 0.9955   | +0.0045     |
| 튜닝 후<br>(GridSearchCV, 트리 100) | 0.9966    | 0.9955   | +0.0011     |

#### ■ 과적합 점검 - 튜닝 전/후 Train vsTest 정확도

| 지표                 | 튜닝 전   | 튜닝 후   | 변화      |
|--------------------|--------|--------|---------|
| Test Accuracy      | 0.9955 | 0.9955 | +0.0000 |
| Test F1<br>(macro) | 0.9955 | 0.9955 | +0.0000 |
| Train-Test Gap     | 0.0045 | 0.0011 | -0.0034 |

#### ■ 하이퍼파라미터 튜닝 전/후 성능 비교

- 해석 : 데이터가 균형·분리 가능하여 Test 정확도는 이미 상한(99.%)에 도달, 튜닝으로 추가 상승은 없었다. 그러나 Train-Test Gap이 0.0045 -> 0.0011로 약 76% 감소하여 과적합이 완화 되었고, 트리 수 200 → 100·깊이 10제한으로 모델이 더 단순·경량화되었다. 즉 '정확도 유지 +일반화·효율 개선'의 실익을 확인 하였다.

#### 4. 프로토타이핑(화면)

##### 4.1 모델 예측

- 슬라이더 7개로 환경값 입력 → 적합 작물 + 신뢰도(확률) Top 3, '왜 이작물?' 비교표 제공

## 스마트팜 작물 추천

토양·환경 값으로 적합 작물 추천 + 모델 평가 (RandomForest 99.5%)

 예측하기

 작물별 환경 가이드

 모델 평가·비교

### 환경값 입력

질소(N)

50.00

인(P)

50.00

칼륨(K)

50.00

온도(°C)

25.00

습도(%)

70.00

산도(pH)

6.50

강수량(mm)

100.00

작물 추천 받기

 추천 작물 : 파파야 (papaya)

### 추천 신뢰도 Top 3

## 4.2 작물별 환경 가이드

○ 작물 선택 → 적합 환경값(평균·최소·최대)을 표로 안내

### 스마트팜 작물 추천

토양·환경 값으로 적합 작물 추천 + 모델 평가 (RandomForest 99.5%)

 예측하기

 작물별 환경 가이드

 모델 평가·비교

### 작물별 적합 환경 가이드

작물을 고르면 그 작물이 잘 자라는 환경값(평균·범위)을 보여줍니다.

작물 선택

강낭콩

|         | 평균       | 최소      | 최대       |
|---------|----------|---------|----------|
| 질소(N)   | 20.8000  | 0.0000  | 40.0000  |
| 인(P)    | 67.5000  | 55.0000 | 80.0000  |
| 칼륨(K)   | 20.0000  | 15.0000 | 25.0000  |
| 온도(℃)   | 20.1000  | 15.3000 | 24.9000  |
| 습도(%)   | 21.6000  | 18.1000 | 25.0000  |
| 산도(pH)  | 5.7000   | 5.5000  | 6.0000   |
| 강수량(mm) | 105.9000 | 60.3000 | 149.7000 |

예: 강낭콩는 강수량 평균 106mm, 습도 22% 환경을 좋아합니다.

#### 4.3 모델 평가 시각화

- 세 모델 정확도 비교표 + 평가 시각화(막대 그래프)를 한 화면에서 제공

## 스마트팜 작물 추천

토양·환경 값으로 적합 작물 추천 + 모델 평가 (RandomForest 99.5%)


 예측하기

 작물별 환경 가이드

 모델 평가·비교

### 세 모델 정확도 비교

| 모델                 | 정확도   | 비고         |
|--------------------|-------|------------|
| RandomForest 🏆     | 99.5% | 베스트(데모 채택) |
| XGBoost            | 99.3% | 강력하나 근소 패  |
| LogisticRegression | 97.3% | 기준선        |





## 5. 결론 및 제안

- 작물 22종을 정확도 99.5%(RandomForest)로 추천하는 분류 모델 개발 및 모델 파일 저장(학습 ↔서빙 분리)
- Streamlit 웹 데모(예측·가이드·평가 3개 탭) 완성 및 평가 시각화 확보
- ML 5단계 골격(수집 → EDA → 전처리 → 학습 → 평가) 체크, '최신 모델이 항상 1등은 아니다' 실증O 한계 및 향후 계획
- 실서비스 제공을 위해서는 국내 실측 데이터가 필요 (현재는 공개 데이터기반)
- 스마트팜 환경은 폐쇄적인 환경(주로 실내) 라서 강수량을 급수량, 급수 주기 와 같은 변수로 치환 필요성 있음.
- DL :원 사진 -> CNN병해충 진단 (정형 ML로 불가능한 이미지 처리 확장)
- LLM : 진단·환경 예측 +재배지식(RAG) → 자연어 처방 및 알림 제공