

2026년도 공공기관 용역과제 AI개발 수행내역서

과제명	AI 기반 스마트팜 작물 추천 모델 개발 및 시각화
담당자	정재봉

2026년 6월 24 일

목차

I. AI개발 수행내용	2
1. 사업과제	2
2. 개요 및 현황	2
2.1 추진배경 및 목적	2
2.2 과제 범위	2
2.3 과제 추진 방법	3
II. 연구개발 주요 결과물	4
1. 데이터 수집	4
2. 데이터 분석	4
2.1 변수 구성	4
2.2 판단 결과(종속변수)	5
2.3 데이터 샘플	5
2.4 데이터 요약	6
2.5 데이터 전처리	6
2.6 변수 상관관계 Heatmap	7
2.7 자동 EDA 프로파일링(YData)	10
3. 데이터 학습 및 모델정의	11
3.1 모델 정의 및 비교	11
3.2 모델 학습 및 평가	12
3.3 하이퍼파라미터 튜닝·과적합 점검	13
4. 프로토타이핑(화면)	14
4.1 모델 예측	14
4.2 작물별 환경 가이드	15
4.3 모델 평가 시각화	16
5. 결론 및 제안	17

AI개발 수행내용

1. 사업과제 : AI 기반 스마트팜 작물 추천 모델 개발 및 시각화

2. 개요 및 현황

2.1 추진배경 및 목적

- 스마트팜 대시보드는 **센서 환경값(온·습도·토양)만** 보여줄 뿐, 무엇을 심고 어떻게 관리할지 판단은 사람의 몫으로 남아 있음
- 단순 임계값 알림(예: 온도 30℃ 초과 시 팬 가동)은 누구나 구현 가능하며 **차별성이 없고**, 데이터 기반의 능동적 의사결정 지원이 부재함
- 장기간 축적되는 환경·토양 데이터를 학습하여, **초보 재배자도 데이터에 근거해 작물을 선택하도록** 돕는 자동 추천 모델의 수요가 증대
- 본 과제는 정형 데이터 기반 작물 추천(시범 모델)을 구축하고, 향후 **잎 사진 병 진단(DL)·자연어 처방(LLM)으로 확대**하기 위한 1단계 모델을 개발하고자 함

2.2 과제 범위

과제구분		내용
AI	AI기반 작물 추천 모델 개발	원시 데이터 수집 및 데이터셋 구축
		데이터 전처리, 표준화, 상관관계 분석 (EDA도구 활용)
		분류 모델 선정 및 학습 (LogReg·RandomForest·XGBoost)
		Accuracy·Precision·Recall·F1-Score 평가지표를 활용한 모델 성능평가
시각화	실시간 환경계측정보 연계 및 시각화	예측실행 웹앱 프로토타입 구축 (Streamlit)
		모델 평가 시각화

2.3 과제 추진 방법

1) 구축 대상 선정 기준

○ 데이터 접근성 및 활용성

- 데이터 수집 및 활용성
- 편의성 : 공개 데이터셋(Kaggle) 및 공공데이터 활용 가능 여부
- 모델학습 유용성 : 종속변수(작물)에 영향을 주는 독립변수 정보 포함 및 적정 학습 데이터양

○ 추천모델 개발 효율성

- 변수가 상대적으로 단순한 구조(수치형 7개)로 학습·평가 과정 간소화 여부
- 개발된 학습·평가 골격을 다른 단계(DL·LLM)에 재사용 가능 여부


○ 재배 의사결정

- 초보 재배자의 시행착오·비용 절감 및 데이터 기반 농업 확산 기여 여부

2) AI 예측 분석모델 적용 대상

추천 기능	수집 데이터	독립 변수	종속 변수
작물 추천/ (스마트팜)	- Kaggle Crop Recommendation 데이터셋 2,200건 - 토양 양분-기후 변수 포함	총 7개 입력 변수 - 토양 양분 : N(질소), P(인), K(칼륨) - 산도 : pH - 기후 : 온도, 습도, 강수량	- 작물 분류(label): 작물 22종

3) AI 분석모델 구축 프로세스



연구개발 주요 결과물

1. 데이터 수집

- Kaggle Crop Recommendation Dataset - 작물 22종 x 100건 = 2,200 건 (입력 7 + 정답 1)

Crop_recommendation								
N	P	K	temperature	humidity	ph	rainfall	label	
90	42	43	20.87974371	82.00274423	6.502985292000000	202.9355362	rice	
85	58	41	21.77046169	80.31964408	7.038096361	226.6555374	rice	
60	55	44	23.00445915	82.3207629	7.840207144	263.9642476	rice	
74	35	40	26.49109635	80.15836264	6.980400905	242.8640342	rice	
78	42	42	20.13017482	81.60487287	7.628472891	262.7173405	rice	
69	37	42	23.05804872	83.37011772	7.073453503	251.0549998	rice	
69	55	38	22.70883798	82.63941394	5.70080568	271.3248604	rice	
94	53	40	20.27774362	82.89408619	5.718627178000000	241.9741949	rice	
89	54	38	24.51588066	83.53521630000000	6.685346424	230.4462359	rice	
68	58	38	23.22397386	83.03322691	6.336253525	221.2091958	rice	
91	53	40	26.52723513	81.41753846	5.386167788	264.6148697	rice	
90	46	42	23.97898217	81.45061596	7.50283396	250.0832336	rice	
78	58	44	26.80079604	80.88684822	5.108681786	284.4364567	rice	
93	56	36	24.01497622	82.05687182	6.98435366	185.2773389	rice	
94	50	37	25.66585205	80.66385045	6.94801983	209.5869708	rice	
60	48	39	24.28209415	80.30025587	7.042299069000000	231.0863347	rice	
85	38	41	21.58711777	82.7883708	6.249050656000000	276.6552459000000	rice	
91	35	39	23.79391957	80.41817957	6.970859754	206.2611855	rice	
77	38	36	21.8652524	80.1923008	5.953933276	224.5550169000000	rice	
88	35	40	23.57943626	83.58760316	5.85393208	291.2986618000000	rice	
89	45	36	21.32504158	80.47476396	6.442475375	185.4974732	rice	
76	40	43	25.15745531	83.11713476	5.070175667	231.3843163	rice	
67	59	41	21.94766735	80.97384195	6.012632591	213.3560921	rice	
83	41	43	21.0525355	82.67839517	6.254028451	233.1075816	rice	

2. 데이터 분석

2.1 변수 구성

구분	변수(영문)	설명	범위
입력 (X)	N	토양 질소	0 ~140
입력 (X)	P	토양 인	5 ~145
입력 (X)	K	토양 칼륨	5 ~ 205
입력 (X)	temperature	평균 온도(°C)	8.8 ~ 43.7
입력 (X)	humidity	상대 습도(%)	14.3 ~ 100.0
입력 (X)	ph	토양 산도	3.5 ~ 9.9
입력 (X)	rainfall	강수량(mm)	20.2 ~ 298.6
정답 (y)	label	적합 작물	22종

2.2 판단 결과 (종속 변수)

○ 분류(label)

- 작물 22종 :rice, maize, jute, cotton, coconut, mango, grapes, apple, orange 등

label

Categorical

High correlation Uniform

Distinct	22	rice	100
Distinct (%)	1.0%	maize	100
Missing	0	jute	100
Missing (%)	0.0%	cotton	100
Memory size	137.9 KiB	coconut	100
		Other value...	1700

More details

○ 클래스 분포 : 22종 x 100 개 완전 균형 → Accuracy지표 신뢰 가능

2.3 데이터 샘플

스마트팜 작물 추천 — Phase 1 EDA (YData Profiling)

Overview Variables Interactions Correlations Missing values Sample

A simple visualization of nullity by column.

Sample

First rows

Last rows


	N	P	K	temperature	humidity	ph	rainfall	label
0	90	42	43	20.879744	82.002744	6.502985	202.935536	rice
1	85	58	41	21.770462	80.319644	7.038096	226.655537	rice
2	60	55	44	23.004459	82.320763	7.840207	263.964248	rice
3	74	35	40	26.491096	80.158363	6.980401	242.864034	rice
4	78	42	42	20.130175	81.604873	7.628473	262.717340	rice
5	69	37	42	23.058049	83.370118	7.073454	251.055000	rice
6	69	55	38	22.708838	82.639414	5.700806	271.324860	rice
7	94	53	40	20.277744	82.894086	5.718627	241.974195	rice
8	89	54	38	24.515881	83.535216	6.685346	230.446236	rice
9	68	58	38	23.223974	83.033227	6.336254	221.209196	rice

Report generated by YData.

2.4 데이터 요약

- 결측치 없음 · 중복 없음 · 22종 x 100개 완전 균형
- 2,200 rows x 8 columns 으로 구성 (입력 7개는 수치형, 정답 1개는 범주형)

Missing values



2.5 데이터 전처리

- 입력 7개가 모두 수치형이라 원-핫 인코딩 불필요, 정답(작물명)만 LabelEncoder로 숫자(0~21) 변환
- 학습/테스트 = 8:2 분할(stratify로 22종 비율 유지) → 1,760/440
- 스케일링은 train 에만 fit후 test는 transform만 적용 → 데이터 누수 방지


```
from sklearn.preprocessing import LabelEncoder, StandardScaler
from sklearn.model_selection import train_test_split

le = LabelEncoder()
y = le.fit_transform(df['label'])      # rice->0 ... coffee->21
X = df.drop(columns=['label'])         # 입력 7개(전부 수치형)

X_tr, X_te, y_tr, y_te = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y)


scaler = StandardScaler()
X_tr = scaler.fit_transform(X_tr)      # train만 fit
X_te = scaler.transform(X_te)          # test는 transform만
```


2.6 변수 상관관계 Heatmap(독립변수 선택)



○ P(인) - K(칼륨) 상관 0.74 외에는 대부분 독립적 → 다중공선성 부담 낮음 → 7개 변수 모두 사용


○ VIF(분산팽창계수)로 정량 검증: 7개 변수 전부 5미만 (최대 칼륨 2.80, 인 2.63) → 상관관계 분석 결론과 일치 → 7개 변수 모두 사용





○입력 변수 7종 분포 (히스토그램)

○ 작물별 강수량 분포가 뚜렷이 다름(머스크멜론 약 25mm vs 벼 약 236mm) → 강수량이 작물 구분의 핵심 변수



○ 작물별 강수량 분포 (박스플롯)

2.7 자동 EDA 프로파일링 (YData Profiling)

- 수동 EDA에 더해 ydata-profiling으로 자동 EDA 리포트를 생성하여,
기초 통계량과 데이터 품질 경고를 객관적으로 보강함

변수	평균	표준편차	최소	중앙값	최대
질소(N)	50.55	36.92	0.00	37.0	140.0
인(P)	53.36	32.99	5.00	51.0	145.0
칼륨(K)	48.15	50.65	5.00	32.0	205.0
온도(°C)	25.62	5.06	8.83	25.6	43.68
습도(%)	71.48	22.26	14.26	80.47	99.98
산도(pH)	6.47	0.77	3.50	6.43	9.94
강수량(mm)	103.46	54.96	20.21	94.87	298.56

- 자동 탐지 경고 11건 :label ↔ (K·P·강수량) 강한연관/ label 균등분포 / 온·습도·pH·강수량 연속형 고유 값 / N 0값 27건(1.2% 결측 아님)

Alerts

K is highly overall correlated with label	High correlation
P is highly overall correlated with label	High correlation
humidity is highly overall correlated with label	High correlation
label is highly overall correlated with K and 3 other fields	High correlation
rainfall is highly overall correlated with label	High correlation
label is uniformly distributed	Uniform
temperature has unique values	Unique
humidity has unique values	Unique
ph has unique values	Unique
rainfall has unique values	Unique
N has 27 (1.2%) zeros	Zeros

3. 데이터 학습 및 모델정의


3.1 모델 정의 및 비교

○ LogisticRegression / RandomForest / XGBoost 세 모델을 통일 데이터로 공정 비교 후 베스트 선정

```
models = {
    'LogisticRegression': LogisticRegression(max_iter=1000),
    'RandomForest': RandomForestClassifier(n_estimators=200, random_state=42, n_jobs=-1),
    'XGBoost': XGBClassifier(n_estimators=200, random_state=42, n_jobs=-1),
}
for name, m in models.items():
    m.fit(X_tr, y_tr)
    print(name, round(accuracy_score(y_te, m.predict(X_te)), 4))
# -> RandomForest 0.995 (best)
```



모델	정확도	비고
LogisticRegression	97.3%	기준선(직선 분리만 가능)
RandomForest	99.5%	★ 베스트 - 데모 채택
XGBoost	99.3%	강력하나 근소 차 2위

⑤ 모델별 정확도 비교



3.2 모델 학습 및 평가 (베스트: RandomForest)

- 혼동행렬 : 테스트 440개 중 438개 정답(오답 2개) - 환경이 닮은 작물도 안정적으로 분리
- 피쳐 중요도 : 강수량 45% > 습도 29% > pH 10% > 온도 9.5% > N·P·K → EDA 결과 와 일치



3.3 하이퍼파라미터 튜닝 및 과적합 점검

- 베이스라인 RandomForest는 Test 정확도가 99.5%로 높으나 Train 정확도가 100%로 학습 데이터를 완벽히 암기하여, 미세한 과적합 경향이 관찰되었다.

이를 완화하기 위해 GridSearchCV(5-fold 교차검증, 후보 36개 조합)로 하이퍼파라미터를 탐색하였다.

- 탐색 대상 : n_estimators(트리 수), max_depth(최대 깊이), min_samples_split, min_samples_leaf

- 최적 조합 : max_depth = 10, min_samples_split = 5, n_estimators = 100, min_samples_leaf = 1

구분	Train Acc	Test Acc	Gap(과적합 정도)
튜닝 전 (기본값, 트리 200)	1.0000	0.9955	+0.0045
튜닝 후 (GridSearchCV, 트리 100)	0.9966	0.9955	+0.0011

■ 과적합 점검 - 튜닝 전/후 Train vs Test 정확도

지표	튜닝 전	튜닝 후	변화
Test Accuracy	0.9955	0.9955	+0.0000
Test F1 (macro)	0.9955	0.9955	+0.0000
Train-Test Gap	0.0045	0.0011	-0.0034

■ 하이퍼파라미터 튜닝 전/후 성능 비교

- 해석 : 데이터가 균형·분리 가능하여 Test 정확도는 이미 상한(99.%)에 도달, 튜닝으로 추가 상승은 없었다. 그러나 Train-Test Gap이 0.0045 -> 0.0011로 약 76% 감소하여 과적합이 완화되었고, 트리 수 200 → 100·깊이 10제한으로 모델이 더 단순·경량화되었다. 즉 '정확도 유지 + 일반화 효율 개선'의 실익을 확인하였다.

4. 프로토타이핑(화면)

4.1 모델 예측

- 슬라이더 7개로 환경값 입력 → 적합 작물 + 신뢰도(확률) Top 3, '왜 이작물?' 비교표 제공

스마트팜 작물 추천

토양·환경 값으로 적합 작물 추천 + 모델 평가 (RandomForest 99.5%)

 예측하기

 작물별 환경 가이드

 모델 평가·비교

환경값 입력

질소(N)

50.00

인(P)

50.00

칼륨(K)

50.00

온도(°C)

25.00

습도(%)

70.00

산도(pH)

6.50

강수량(mm)

100.00

작물 추천 받기

 추천 작물 : 파파야 (papaya)

추천 신뢰도 Top 3

4.2 작물별 환경 가이드

○ 작물 선택 → 적합 환경값(평균·최소·최대)을 표로 안내

스마트팜 작물 추천

토양·환경 값으로 적합 작물 추천 + 모델 평가 (RandomForest 99.5%)

 예측하기

 작물별 환경 가이드

 모델 평가·비교

작물별 적합 환경 가이드

작물을 고르면 그 작물이 잘 자라는 환경값(평균·범위)을 보여줍니다.

작물 선택

강낭콩

	평균	최소	최대
질소(N)	20.8000	0.0000	40.0000
인(P)	67.5000	55.0000	80.0000
칼륨(K)	20.0000	15.0000	25.0000
온도(℃)	20.1000	15.3000	24.9000
습도(%)	21.6000	18.1000	25.0000
산도(pH)	5.7000	5.5000	6.0000
강수량(mm)	105.9000	60.3000	149.7000

예: 강낭콩는 강수량 평균 106mm, 습도 22% 환경을 좋아합니다.

4.3 모델 평가 시각화

- 세 모델 정확도 비교표 + 평가 시각화(막대 그래프)를 한 화면에서 제공

스마트팜 작물 추천

토양·환경 값으로 적합 작물 추천 + 모델 평가 (RandomForest 99.5%)


 예측하기

 작물별 환경 가이드

 모델 평가·비교

세 모델 정확도 비교

모델	정확도	비고
RandomForest 🏆	99.5%	베스트(데모 채택)
XGBoost	99.3%	강력하나 근소 패
LogisticRegression	97.3%	기준선



5. 결론 및 제안

- 작물 22종을 정확도 99.5%(RandomForest)로 추천하는 분류 모델 개발 및 모델 파일 저장(학습 ↔서빙 분리)
- Streamlit 웹 데모(예측·가이드·평가 3개 탭) 완성 및 평가 시각화 확보
- ML 5단계 골격(수집 → EDA → 전처리 → 학습 → 평가) 체크, '최신 모델이 항상 1등은 아니다' 실증O 한계 및 향후 계획
- 실서비스 제공을 위해서는 국내 실측 데이터가 필요 (현재는 공개 데이터기반)
- 스마트팜 환경은 폐쇄적인 환경(주로 실내)라서 강수량을 급수량, 급수 주기 와 같은 변수로 치환 필요성 있음.
- DL :원 사진 -> CNN병해충 진단 (정형 ML로 불가능한 이미지 처리 확장)
- LLM : 진단·환경 예측 +재배지식(RAG) → 자연어 처방 및 알림 제공